

中图法分类号: TP391 文献标识码: A 文章编号: 1006-8961(2024)04-0841-21

论文引用格式: Hu Z Y, Zhou Q, Chen M J, Cui J C, Wu X F and Zheng B Y. 2024. Survey of image deblurring. Journal of Image and Graphics, 29(04):0841-0861(胡张颖, 周全, 陈明举, 崔景程, 吴晓富, 郑宝玉. 2024. 图像去模糊研究综述. 中国图象图形学报, 29(04):0841-0861)
[DOI:10.11834/jig.230555]

图像去模糊研究综述

胡张颖¹, 周全^{1*}, 陈明举², 崔景程¹, 吴晓富¹, 郑宝玉¹

1. 南京邮电大学通信与信息工程学院, 南京 210003; 2. 四川轻化工大学人工智能四川省重点实验室, 宜宾 644000

摘要: 图像模糊是指在图像捕捉或传输过程中, 由于镜头或相机运动、光照条件等因素导致图像失去清晰度和细节, 从而影响图像的质量和可用性。为了消除这种影响, 图像去模糊技术应运而生。其目的在于通过构建计算机数学模型来衡量图像的模糊信息, 从而自动预测去模糊后的清晰图像。图像去模糊算法的研究发展不仅为计算机视觉领域的其他任务提供了便利, 如目标检测等, 同时也为生活领域提供了便捷和保障, 如安全监控等。1) 本文回顾了图像去模糊领域的发展历程, 对盲图像去模糊和非盲图像去模糊中具有影响力的算法进行论述和分析。2) 讨论了图像模糊的常见原因以及去模糊图像的质量评价方法。3) 全面阐述了传统方法和基于深度学习方法的基本思想, 并针对图像非盲去模糊和图像盲去模糊两方面的一些文献进行了综述。其中, 基于深度学习的方法包括基于卷积神经网络、基于循环神经网络、基于生成式对抗网络和基于Transformer的方法等。4) 简要介绍了图像去模糊领域的常用数据集并比较分析了一些代表性图像去模糊算法的性能。5) 给出了本文结论, 探讨了图像去模糊领域所面临的挑战, 并对未来的研究方法进行了展望。

关键词: 图像去模糊; 卷积神经网络(CNN); 循环神经网络(RNN); 生成式对抗网络(GAN); Transformer; 深度学习

Survey of image deblurring

Hu Zhangying¹, Zhou Quan^{1*}, Chen Mingju², Cui Jingcheng¹, Wu Xiaofu¹, Zheng Baoyu¹

1. School of Communication and Information Engineering, Nanjing University of Posts and Telecommunications, Nanjing 210003, China;

2. Artificial Intelligence of Key Laboratory of Sichuan Province, Sichuan University of Science and Engineering, Yibin 644000, China

Abstract: Image blurring refers to the loss of clarity and detail in an image during its capture or transmission due to factors such as motion of the lens or camera, lighting conditions, and other environmental variables. This loss of quality and usability can significantly influence the overall visual impact of the image. The technique of image deblurring has been developed to mitigate such effects. Its purpose is to predict the clear version of an image automatically by constructing computer mathematical models that measure the blurriness of the image. The research and development of image deblurring algorithms have not only provided convenience for other tasks in the field of computer vision, such as object detection, but have also offered assurance in various aspects of life, including security monitoring. Depending on its cause, blurring can mainly be divided into motion blur, out-of-focus blur, and Gaussian blur. Out-of-focus and Gaussian blurs are less prevalent and relatively easier to handle, whereas motion blur is more likely to occur in situations such as road traffic cameras,

收稿日期: 2023-07-31; 修回日期: 2023-10-17; 预印本日期: 2023-10-24

* 通信作者: 周全 quan.zhou@njupt.edu.cn

基金项目: 国家自然科学基金项目(61876093); 人工智能四川省重点实验室开放基金项目(2023RYY08); 江苏省研究生实践创新项目(KYCX22_0962)

Supported by: National Natural Science Foundation of China (61876093); Project of Sichuan Provincial Key Laboratory of Artificial Intelligence (2023RYY08); Postgraduate Research & Practice Innovation Program of Jiangsu Province (KYCX22_0962)

pedestrian movement, and fast-moving vehicles, making it a more critical issue to be addressed. After an image is deblurred, evaluating the quality of the results becomes essential, which is carried out using methods for image quality assessment (IQA), categorized as either subjective or objective. Objective evaluation methods can be divided into three types: full-reference, reduced reference, and no reference. Owing to constraints in resources, objective evaluation methods make up the majority of IQA approaches. The process of image blurring can be represented as the convolution of a clear image with a blur kernel, accompanied with greater or lesser degrees of noise. Therefore, image deblurring comprises two types: non-blind image deblurring (NBID) and blind image deblurring (BID). Non-blind deblurring involves the restoration of an image with a known blur kernel, requiring prior knowledge of the blur kernel's parameters. On the contrary, blind deblurring aims to restore images with unknown blur kernels or unknown clear images, posing a more challenging problem to solve because of the increased number of unknown factors. In light of these considerations, we systematically and critically review the recent advancements in image deblurring. A comprehensive and systematic introduction of image deblurring is presented from the following two aspects: 1) the evolution of traditional image deblurring and 2) the development of deep learning-based image deblurring. From the perspective of traditional image deblurring, the existing image deblurring methods can be divided into two categories: non-blind deblurring and blind deblurring. Specifically, traditional NBID algorithms rely on prior knowledge of the blur kernel for the restoration process. Common methods include denoising- and iteration-based methods. Traditional BID methods primarily involve estimating the blur kernel first and transforming it into an NBID problem afterward. The kernel and clear image are often estimated iteratively until satisfactory results are obtained. The emerging deep learning methods extract blur image features through training a neural network and employing logistic regression to update models. Unlike traditional methods that require prior knowledge of the degree of image blur, deep learning-based methods are capable of directly processing blurry images without the need for prior estimation of the blur degree. From the perspective of network architecture, deep learning-based image deblurring algorithms can be classified into convolutional neural network (CNN)-based, recurrent neural network (RNN)-based, generative adversarial network (GAN)-based, and Transformer-based networks. CNN-based methods can learn the mapping between blurry and clear images by training on a large number of image pairs, which enables them to perform blind deblurring. These algorithms take advantage of parameter sharing and local receptive fields, reducing the number of model parameters and improving the accuracy of image feature extraction. Image deblurring based on RNN is a type of neural network model that can handle sequential data through learning the relationship between sequential data. GAN-based deblurring approaches define image deblurring problems as an adversarial game between generators and discriminators. Transformer-based methods employ a self-attention mechanism to encode global dependencies between different spatial positions, thereby capturing the global information of an entire image. Our critical review focuses on the main concepts and discussions of the characteristics of each method for image deblurring from the perspective of network architecture. Particularly, we summarize the limitations of different deblurring algorithms. We also briefly introduce popular public datasets. Then, we review some image deblurring literature from two aspects: traditional methods and deep learning-based methods. The capability of representative algorithms is analyzed using peak signal-to-noise ratio and structural similarity evaluation indexes in terms of GoPro Labs, human-aware motion deblurring, and other datasets. Furthermore, this review critically analyzes the conclusion, highlighting the challenges in image deblurring.

Key words: image deblurring; convolutional neural network (CNN); recurrent neural network (RNN); generative adversarial network (GAN); Transformer; deep learning

0 引言

图像模糊是由于图像采集过程中的成像设备自身的散焦、抖动或图像物体运动等因素导致的(Joshi等, 2008; Sun等, 2015)。例如, 拍摄运动中的物体

时, 快门时间较长或手持相机不稳定, 会导致图像模糊。而这种模糊会降低图像的质量, 影响图像的视觉感受效果和有效信息提取。为了解决这个问题, 图像去模糊技术应运而生。通过运用先进的算法和技术, 可以将模糊的图像转化为清晰、锐利的图像, 并重新展现其细节和质感。这种图像去模糊技术在

医疗(Sharif等,2023)、安防监控(马苏欣等,2019)、图像分类(He等,2016)、目标检测(Isola等,2017)等领域具有重要的应用价值。因此,研究如何对这些图像进行去模糊成为底层计算机视觉领域的一项重要任务,并具有广泛的应用前景。

根据造成图像模糊的原因,模糊类型主要可以分为运动模糊(motion blur)、散焦模糊(out-of-focus blur)和高斯模糊(Gaussian blur)(Zhang等,2022)。目前的研究主要关注解决图像运动模糊问题,因为相比于散焦模糊和高斯模糊,图像运动模糊更常见且较难处理。特别是在拍摄运动物体或快速移动场景时,图像容易受到运动模糊的影响。在进行图像去模糊后,需要对处理结果进行评价。常用的方法是图像质量评价(image quality assessment, IQA),IQA可以分为主观评价和客观评价两类(程茹秋等,2022),而客观评价方法又可分为全参考(Wang等,2017)、半参考(Liu等,2018)和无参考(Mittal等,2012;Kang等,2014)3类。鉴于主观评价方法需要耗费大量人力物力资源,在实际应用中更多采用客观评价方法。

传统图像去模糊方法可以被视为反向求解图像模糊模型的问题。当整个图像模糊是均匀的时,模糊模型可以建模为模糊图像与模糊核的卷积过程(Fergus等,2006;Chen等,2019)。在已知模糊核的情况下,可称之为非盲去模糊问题(Yuan等,2008),早期采用图像先去噪后反卷积或迭代求解模糊过程两种算法来处理这些模糊图像。而在未知模糊核或清晰图像的情况下,则属于盲去模糊问题(Krishnan等,2011),传统方法主要通过估计模糊核,再转变为非盲图像去模糊问题。然而,传统方法更适用于均匀模糊,对于多物体运动和复杂环境下的非均匀

模糊效果不佳。随着深度学习的发展,基于端到端的深度学习图像去模糊的方法相继提出。相比于传统图像去模糊的方法,基于深度学习的方法能够自动学习图像模糊过程中的深度特征,避免模糊核估计过程。这些方法包括基于卷积神经网络(convolutional neural network, CNN)(Nah等,2017;Cho等,2021)、基于循环神经网络(recurrent neural network, RNN)(Zhang等,2018;Gao等,2019)、基于生成对抗网络(generative adversarial network, GAN)(Kupyn等,2018)和基于Transformer(Wang等,2022)等。

本文结构如图1所示。对图像去模糊领域的研究进展进行全面综述,分别从传统图像去模糊方法和基于深度学习的一些新兴方法两个方面展开论述。首先,回顾图像去模糊的发展历程,然后介绍不同类型的模糊和质量评价指标。接着,详细讨论图像去模糊的传统方法和基于深度学习模型的方法。在传统方法方面,根据模糊核是否已知对其进行分类;而在基于深度学习的方法方面,则根据网络模型架构进行细分,并阐述不同网络模型方法的应用。然后,介绍图像去模糊领域的公共基准数据集以及对具有代表性的算法进行全面评估分析。最后,分析图像去模糊领域所面临的挑战,并对存在的一些问题进行总结和展望。

Zhang等人(2022)的综述更多关注基于深度学习的图像和视频去模糊的方法,而本篇综述深入探讨了图像去模糊领域传统方法和基于深度学习的方法之间的区别和联系,以及近期在图像去模糊任务中应用和研究的Transformer方法。相较现有综述,本文更全面地梳理了图像去模糊领域的进展,并对相关领域起到借鉴和推动的作用。

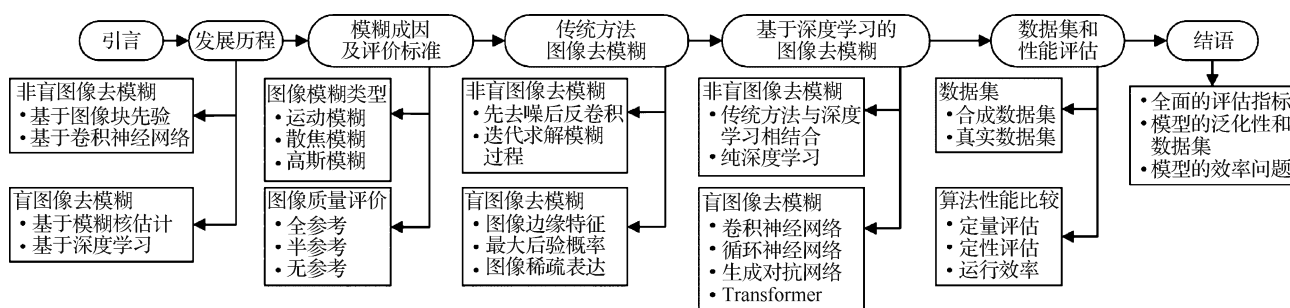


图1 本文架构

Fig. 1 The architecture of this paper

1 图像去模糊方法的发展历程

图像去模糊领域自20世纪60年代发展至今,产生了许多具有影响力的工作。传统的图像去模糊方法大都采用线性模型进行建模,无法有效应对复杂先验分布下的图像去模糊问题。随着深度学习技术的日益发展,深度学习模型可以利用大量的训练数

据自主选择特征,并借助其自身非线性特性广泛应用于图像去模糊问题。本文对图像去模糊自2005年以来的发展进行总结,图2按时间轴在图像非盲去模糊和图像盲去模糊两个领域展示了一些传统方法和深度学习方法。其中黄色箭头表示被广泛认为较为经典的算法,并对这些算法名称使用加粗字体;蓝色和紫色箭头分别表示非盲图像去模糊和盲图像去模糊中较具有代表性的算法。

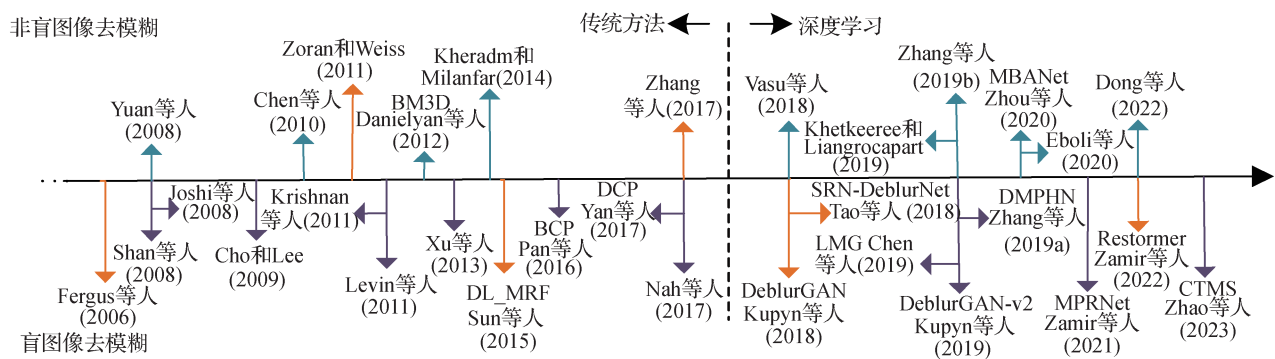


图2 图像去模糊的发展历程

Fig. 2 Chronology of classical methods for image deblurring

1.1 非盲图像去模糊

1.1.1 基于图像块先验的非盲图像去模糊

Zoran 和 Weiss(2011)采用高斯混合模型对图像块进行建模,并将学习到的图像特征作为去模糊的正则化项。该方法证明了使用小图像块时,可以非常有效地学习先验信息以进行图像恢复,引起了很多研究人员的广泛关注。其他代表性的工作包括:先去噪后反卷积(Chen 等,2010;Danielyan 等,2012)和迭代求解模糊过程(Yuan 等,2008;Kheradmand 和 Milanfar, 2014; Khetkeeree 和 Liangrocapart, 2019)的图像去模糊方法。

1.1.2 基于卷积神经网络的非盲图像去模糊

模型优化和判别式学习是解决底层视觉任务中逆问题的两种策略,Zhang 等人(2017)将两种方法进行结合,训练快速有效的CNN去噪器,以解决非盲图像去模糊问题。随着深度学习的发展,其他具有代表性的工作还包括:传统方法与深度学习相结合的方法(Zhang 等,2019b;Dong 等,2022)和纯深度学习的方法(Vasu 等,2018;Zhou 等,2020;Eboli 等,2020)。

1.2 盲图像去模糊

1.2.1 模糊核估计的盲去模糊方法

Fergus 等人(2006)的方法摒弃了以往盲去模糊

方法对卷积核或图像的先验假设,实现了真正意义上的盲图像去模糊。这类方法重点集中在未知模糊核的估计上,因为一旦能够准确估计模糊核,任何非盲去模糊算法都可以用估计的模糊核对图像进行去模糊。传统盲图像去模糊具有代表性的工作还包括以下几种方法:基于图像边缘特征的方法(Joshi 等,2008;Chen 等,2019);基于最大后验概率(maximum a posteriori, MAP)的方法(Shan 等,2008;Cho 和 Lee, 2009; Levin 等,2011);基于图像稀疏表达的方法(Krishnan 等,2011;Pan 等,2016;Yan 等,2017)。

1.2.2 基于深度学习的盲去模糊方法

Sun 等人(2015)首次将CNN应用到图像去模糊领域,是图像去模糊领域的一个重要转折点。它利用图像块统计信息来建模非均匀运动模糊,并取得了显著效果。随着深度学习的发展,盲图像去模糊的代表性工作还包括:基于卷积神经网络的方法(Nah 等,2017;Zamir 等,2021);基于循环神经网络的SRN-DeblurNet(scale-recurrent network for deep image deblurring)(Tao 等,2018);基于生成对抗网络的DeblurGAN(Kupyn 等,2018)和在其改进DeblurGAN-v2(Kupyn 等,2019);基于Transformer的

Restormer (Zamir 等, 2022) 和 CTMS (CNN-Transformer multiscale structure)(Zhao 等, 2023)。这些深度学习的方法要么估计模糊核再进行反卷积去模糊, 要么采用端到端的方法, 直接从模糊图像预测清晰图像。

2 图像模糊成因及评价标准

图像模糊是由多种原因引起的, 主要包括运动模糊、散焦模糊和高斯模糊, 使得图像中的细节不清晰、边缘模糊或整体呈现出模糊的效果(Zhang 等, 2022)。在对图像进行去模糊处理后, 需要评估图像的清晰度, 通常采用一些图像质量评价标准来衡量图像的质量。这些评价标准能够确定恢复图像是否清晰, 并提供一种客观的方式来比较不同图像处理算法的性能。下面分别从模糊成因和图像评价标准进行综述。

2.1 常见的模糊类型

图像在获取和存储过程中存在着许多不确定的因素, 无论是拍摄时物体的快速移动或相机设备的抖动等形成的运动模糊, 还是相机设备聚焦不当造成的散焦模糊, 或是天气因素产生的高斯模糊。模糊类型错综复杂, 但图像模糊过程可以统一建模为

$$Y = X \otimes K + N \quad (1)$$

式中, X 为清晰图像, Y 为模糊图像, K 为模糊核或点扩散函数(point spread function, PSF), 其中 \otimes 为卷积操作, N 为加性噪声。整个图像模糊过程可以表示为原始清晰图像 X 与模糊核 K 进行卷积运算, 并加上噪声得到模糊图像 Y 。

2.1.1 运动模糊

根据模糊区域, 可以将运动模糊划分为全局运动模糊和局部运动模糊两类(刘利平等, 2022)。全局运动模糊是指整个图像在同一方向上发生模糊, 通常是由相机或物体的移动造成(Pan 和 Su, 2013; Yan 等, 2017)。例如, 当在拍摄运动车辆时, 由于相机或车辆移动, 图像中的车辆会变得模糊不清, 这就属于全局运动模糊。局部运动模糊是指图像中只有某些区域发生模糊, 通常是由物体的运动或相机焦距的变化造成(Dai 和 Wu, 2008)。例如, 当在拍摄一个人物时, 如果他的手或头部移动了, 这些区域就可能出现局部运动模糊。通常情况下, 大多数运动模糊的模糊核是不清楚的, 因此运动模糊大多是图像

盲去模糊问题。

2.1.2 散焦模糊

散焦模糊通常是因为相机或镜头无法将图像的所有部分聚焦在同一平面上, 导致图像变得模糊不清(Shen 等, 2012; 衡红军等, 2021; Quan 等, 2023)。当相机或镜头无法正确对焦时, 图像中的物体会失去清晰度, 看起来模糊或者像是被涂上一层薄雾。散焦模糊的点扩散函数表示为

$$F(x, y) = \begin{cases} \frac{1}{\pi R^2} & \sqrt{x^2 + y^2} \leq R \\ 0 & \text{其他} \end{cases} \quad (2)$$

式中, $F(x, y)$ 表示模糊核在位置 (x, y) 处的像素值, R 表示散焦模糊半径。

2.1.3 高斯模糊

对于每个像素, 将其周围的像素按照高斯分布函数计算权重, 然后将这些像素的值加权平均, 得到一个新的像素值。这个过程在整幅图像上重复进行, 从而得到一幅模糊的图像, 这种称为高斯模糊(Bar 等, 2006; Chen 和 Ma, 2009; Wang 等, 2010)。高斯模糊的点扩散函数表示为

$$G(x, y) = \frac{1}{2\pi\sigma^2} e^{-\frac{x^2+y^2}{2\sigma^2}} \quad (3)$$

式中, σ 表示高斯模糊的标准差, 也称为模糊半径, 模糊半径越长, 图像模糊程度越高。 $G(x, y)$ 表示模糊核在位置 (x, y) 处的像素值。

2.2 图像质量评价

图像去模糊质量评价分为主观评价和客观评价两类(程茹秋等, 2022)。主观评价是指人们从感性认识的视觉和经验角度对图像质量进行主观判定。由于需要人为打分得到平均主观分数(mean opinion score, MOS)(HoBfeld 等, 2016)来评估图像质量, 因而往往这种评价机制更加符合人眼视觉特性。但是主观打分容易受到主观影响, 而且需要耗费大量的人力, 成本高效率低。因此, 大多图像质量评价以客观评价为主, 再进一步划分为全参考(full-reference, FR)(Wang 等, 2017)、半参考(reduced-reference, RR)(Liu 等, 2018)和无参考(no-reference, NR)(Mittal 等, 2012)图像质量评价。

2.2.1 全参考图像质量评价(FR-IQA)

FR-IQA 是基于原始图像和失真图像之间的差异来评估图像质量。广泛采用的评价指标包括均方误差(mean square error, MSE)(Haigh, 1980)和峰值

信噪比(peak signal to noise ratio, PSNR)(Huynh-Thu和Ghanbari, 2008)。然而,这两种方法被认为与人类视觉系统(human visual system, HVS)不符。因此,先后提出了基于结构相似度(structural similarity, SSIM)(Wang等, 2004)和基于HVS的评价方法。

SSIM通过比较原始图像 X 与复原图像 Y 之间的结构信息变化来衡量图像质量。然而,SSIM在评估图像质量方面的效果并不理想,Chen等人(2006)提出基于梯度的结构相似度(gradient-based structural similarity, GSSIM)方法,利用边缘信息作为重要的图像结构信息,并使用梯度代替结构相似度中的对比度和结构度量。因为图像模糊会减弱图像中包含的语义信息,为此Zhang等人(2013)提出ESSIM(edge strength similarity-based image quality metric)方法,通过计算边缘强度相似性来衡量由语义感知导致的质量退化。

HVS算法主要利用人眼的亮度适应性、边缘敏感性、多尺度和掩蔽效应等多种特性来衡量图像质量。Chandler和Hemami(2007)提出基于小波的自然图像视觉信噪比方法,用于量化失真图像的视觉保真度。Larson和Chandler(2010)认为用HVS判断图像质量时往往采用单一的策略(如提取图像结构信息)往往是不够的,因此提倡HVS使用多策略来衡量图像质量,对于高质量图像,采用局部亮度和对比度来感知失真;对于低质量图像,采用空间频率分量的局部统计变化来感知失真。Zhang等人(2011)将相位一致性作为主要特征,图像梯度的幅度作为次要特征提出了基于HVS底层特征的图像质量评价算法。

2.2.2 半参考图像质量评价(RR-IQA)

RR-IQA一般基于图像的部分信息而非完整信息来进行质量评价。相比于FR-IQA,RR-IQA具有灵活性,适用性强和传输数据量小等特点。RR-IQA的代表性工作是采用变换域方法进行质量评估(Wang等, 2006; Li和Wang, 2009)。Wang等人(2006)提出一种基于小波变换域的自然图像统计模型。该模型使用小波系数对原始图像进行编码,并通过比较解码后的系数分布与原始图像系数分布的偏差来量化图像的质量。Li和Wang(2009)将分裂归一化和小波变换结合,利用小波变换高斯混合模型计算图像的分裂归一化变换,在变换域提取特征进行质量评估。此外,另一类RR-IQA方法采用稀

疏表达进行质量评价(Liu等, 2018; Wan等, 2020)。Liu等人(2018)利用稀疏表达分别预测参考图像和失真图像,然后通过预测误差熵之间的差值衡量图像质量。而Wan等人(2020)提出使用稀疏表达和自然场景统计特性来模拟大脑视觉感知的RR-IQA。

2.2.3 无参考图像质量评价(NR-IQA)

FR-IQA和RR-IQA都需要借助原始清晰图像作为参考,并通过计算特征差异或统计度量来评估图像质量,但所得到的结果并不能很好地满足HVS。因此,NR-IQA应运而生。NR-IQA通过建立图像与主观质量评分之间的映射关系进行质量评价,从而更加符合人眼的主观性。在NR-IQA模型中,当算法评价与MOS值越接近、相关性越强,说明评价越准确,反之亦然。

无参考方法中的自然场景统计(natural scene statistical, NSS)方法是指高质量图像的视觉特征(如亮度、梯度等)服从一定的分布规律,而不同类型或不同程度的失真会对这种分布产生影响(方玉明等, 2021)。Moorthy和Bovik(2011)和Mittal等人(2012)分别提出DIIVINE和BRISQUE方法。DIIVINE使用两阶段框架,首先用提取的场景统计信息预测失真类型,然后利用预测结果评估图像质量。而BRISQUE模型采用空间域中的NSS模型提取图像特征进行图像质量评价。

尽管基于NSS的方法对部分失真效果较好,但由于外界因素的复杂性,这些方法还不能有效应对各种失真。为此,Kang等人(2014)提出将CNN应用到NR-IQA,利用CNN网络架构对图像块进行特征提取,然后建模图像特征和评价分数之间的映射关系。Li等人(2016)提出了端到端CNN模型,直接以原始图像作为输入并输出图像质量分数。受无监督预训练方法启发,Madhusudana等人(2022)将图像质量评价从一个回归问题转化为分类问题,设计了一种基于对比学习的IQA训练框架。使用失真类型和失真程度作为辅助任务,从未标记的数据集中学习特征,进行正确的归类。对辅助任务训练得到的模型进行图像评估,从而得到质量分数。

3 传统方法图像去模糊

如图1所示,2017年之前图像去模糊主要采用传统方法,下面从非盲去模糊和盲去模糊两个方面

回顾经典工作。

3.1 非盲图像去模糊

传统的非盲图像去模糊算法主要关注如何在噪声干扰的情况下,能够有效地恢复出清晰图像(杨航,2022)。因此,非盲图像去模糊主要从以下两类方法进行考虑:先去噪后反卷积(Chen等,2010; Danielyan等,2012)或迭代求解模糊过程(Zoran和Weiss,2011)。

3.1.1 先去噪后反卷积

在图像去模糊领域,早期的研究包括Wiener(1964)提出的自适应方差最小化滤波器,也被称为维纳滤波。该方法通过信号和噪声的统计特性来计算滤波器的权重,然后将这些权重应用于原始信号以滤除噪声的干扰,再进行反卷积实现去模糊。Kalifa等人(2003)将小波技术融合到反卷积中,提出了一种能匹配卷积核频域性质的镜像小波,通过阈值收缩来达到抑制噪声的目的。由于非局部均值滤波具有较强的纹理保持和滤波能力,Chen等人(2010)使用非局部均值滤波来减少彩色噪声,从而在去模糊过程中更好地捕捉了模糊图像中细腻的纹理信息。Danielyan等人(2012)借鉴了三维图像块匹配滤波(block matching 3D filtering, BM3D)(Dabov等,2007)的思想,将其应用于图像去模糊来滤除噪声。

3.1.2 迭代求解模糊过程

尽管滤除噪声有益于后续反卷积操作,但在没有足够先验信息的情况下可能会出现振铃效应(Mosleh等,2018)或者噪声滤波不完全的问题。因此,许多学者从迭代优化的角度改善非盲图像恢复效果。Lucy(1974)基于贝叶斯理论提出了Richardson-Lucy迭代算法,利用最大似然估计对模糊图像进行非线性迭代,不断优化去模糊图像结果。Yuan等人(2008)提出了一种由粗到细的渐进式反卷积方法。通过在每个尺度上迭代应用双边正则化,可以恢复图像的细节和边缘,同时避免振铃效应。Krishnan和Fergus(2009)通过迭代优化图像的稀疏表达来估计图像的梯度分布,从而达到去模糊的效果。

迭代方法在很大程度上受正则化项的选择影响,因此选择适当的正则化项可以更好地解决去模糊问题。Zoran和Weiss(2011)采用高斯混合模型对图像块进行建模,利用学习得到的图像特征作为正

则项进行非盲去模糊。Kheradmand和Milanfar(2014)提出一种基于核相似度的图像去模糊方法,通过估计相似度的权重来调整拉普拉斯正则化项和数据保真项组成的损失函数。Lanza等人(2016)提出一种变分正则化模型,通过使用参数化正则化项来稀疏表达图像梯度值,以恢复因加性高斯噪声而损坏的图像。Khetkeeree和Liangrocapart(2019)设计一种基于维纳滤波的正则项,减轻了对先验信息的依赖,提高了去模糊图像的质量。

3.2 盲图像去模糊

虽然非盲去模糊方法取得了一系列进展,但在实际场景中,图像的模糊核通常难以估计,因此这类方法对于解决实际图像去模糊问题存在一定局限性。传统的盲去模糊方法先通过模糊核估计,再转变为非盲图像去模糊问题。这两个过程也可以迭代进行,交替估计模糊核和清晰图像,直到优化到满意的结果为止。估计模糊核常见方法有基于图像边缘特征(Xu和Jia,2010;Chen等,2019)、最大后验概率(Shan等,2008;Levin等,2011)和图像稀疏表达(Xu等,2013)的方法。

3.2.1 基于图像边缘特征的方法

图像边缘特征是指图像中明显的亮度变化或颜色变化所形成的边界或轮廓。Joshi等人(2008)用高斯边缘检测器检测到的边缘特征来预测模糊核。然而过度强调边缘并非总是有利于核估计,Xu和Jia(2010)引入了一个新的指标来衡量图像边缘在去模糊中的有用性,并基于该指标对边缘进行梯度选择,提高了模糊核估计的准确性。Yang和Ji(2019)从变分贝叶斯推理的角度重新解释了边缘选择的重要性,开发了一种内置自适应边缘选择的变分期望最大化算法,以去除图像模糊。Chen等人(2019)则提出了一种基于局部最大梯度先验的盲去模糊框架,用图像的梯度信息来检测边缘,从而解决了图像模糊处理后,局部块最大梯度值减小的问题。

3.2.2 基于最大后验概率的方法

最大后验概率估计是一种基于贝叶斯统计思想的参数估计方法,通过最大化后验概率来选择参数值。它结合了观测数据和先验知识,提供了对未知量的估计。Fergus等人(2006)提出了在已知观测图像情况下,最大化原始图像和模糊核的联合后验概率,实现同时进行模糊核估计和去模糊过程。Jia(2007)从物体边界透明度与图像运动模糊之间的关

系出发,提出了用透明度信息求解 MAP 问题来估计模糊核。Shan 等人(2008)则基于 MAP 准则,对图像的平滑区域和纹理区域进行约束,通过引入逐块连接函数来解决图像梯度的长尾分布问题,并将连接函数与局部先验联合进行图像去模糊。而 Cho 和 Lee(2009)提出一种对模糊核进行 MAP 估计,对模糊图像采用稀疏表达的方法来实现图像去模糊。Levin 等人(2011)在 Fergus 等人(2006)的基础上,对 MAP 算法进行优化,并结合变分正则化算法对模糊图像进行反卷积。

3.2.3 基于图像稀疏表达的方法

图像稀疏表达是通过选择适当的变换,将图像转换到一个稀疏表达的域中。通过稀疏表达,可以将图像的高频和低频部分有效地分离,并减少噪声和伪影的产生(Donoho, 2006)。Krishnan 等人(2011)在图像的高频上进行核估计,因为他们发现图像的高频部分具有稀疏性,可以用来区分清晰和模糊图像。而 Xu 等人(2013)提出一个可以用于均匀或非均匀模糊的统一去模糊框架,通过图像的高稀疏性来约束由损失函数组成的正则化项,从而实现了去模糊过程。谭海鹏等人(2015)对遥感图像进行去模糊研究,首先用滤波器进行预处理,再结合模糊核的稀疏特性,使用正则化求解模糊核。Pan 等人(2016)用数学方法证明模糊过程会增加暗通道像素的值,因此可以利用暗通道的稀疏性来进行盲去模糊。Yan 等人(2017)引入明通道的定义,并利用了明暗通道各自的优点,更有效地去除图像模糊。

4 基于深度学习的图像去模糊

如图 1 所示,2017 年之后图像去模糊主要采用深度学习方法,以下同样也从非盲去模糊和盲去模糊两方面进行综述。

4.1 非盲图像去模糊

如 3.1 节所述,传统的非盲图像去模糊方法(Danielyan 等, 2012; Khetkeeree 和 Liangrocapart, 2019)大多采用线性模型进行建模,不能很好地处理复杂先验分布下的图像非盲去模糊问题。与传统非盲去模糊方法不同,深度学习方法具有更强的非线性建模能力,能够提取更丰富的特征表示,从而提高去模糊效果。现有方法可以分为传统方法与深度学习相结合(Schuler 等, 2013)和纯深度学习方法

(Zhang 等, 2017; Eboli 等, 2020)。

4.1.1 传统方法与深度学习相结合方法

与深度学习结合的首要方式是正则化。Schmidt 等人(2013)通过分析半二次正则化(half quadratic regularization, HQR)和稀疏图像先验,推导出判别级联的回归树模型建模图像去模糊问题。Schuler 等人(2013)则提出采用傅里叶域的正则化方法来恢复清晰图像,并结合多层感知器去除伪影。Xie 等人(2019)构建一个基于全变分的深度网络,该网络能够自适应学习正则化的最佳参数,从而实现更好的图像去模糊效果。

然而,选择合适的正则化项并非易事。因此,研究人员也尝试从其他的角度来解决图像非盲去模糊问题。Schmidt 和 Roth(2014)将卷积层和傅里叶变换相结合,提出一种适用于图像恢复的新型随机场模型,提高了计算效率和图像恢复质量。Zhang 等人(2019b)设计一种深度图像超分辨率双立方退化模型(bicubic degradation model, BDM),通过可变分方法推导出即插即用算法,实现可以处理任意模糊核的模糊图像。基于 MAP 框架非盲去模糊方法需要定义合适的数据和正则化项,但先前工作大多都集中推进两种关键成分之一。而 Dong 等人(2021)提出在 MAP 框架内联合学习空间变化数据和正则化项,预测每像素的空间变化特征,而不是常用的空间均匀特征,从而改善了图像细节的恢复。Dong 等人(2022)在多尺度级联特征细化模块中将维纳滤波和深层卷积特征相结合,端到端训练图像去模糊模型。

4.1.2 纯深度学习的方法

将传统方法和深度学习结合在一定程度上可以提升图像去模糊的性能,但这类方法一般需要人工的提取特征和预处理。为了缓解这种情况,Zhang 等人(2017)直接采用 CNN 模型进行端到端去模糊,取得了较好的效果。Vasu 等人(2018)利用深度 CNN 去除核估计中存在的伪影,并增强图像细节,实现了非盲图像去模糊。受传统的从粗到细的方法启发,Zhou 等人(2020)采取多尺度策略对输入图像进行处理,将低级信息和高级语义信息集成,有效提取了图像特征,从而提高了图像去模糊性能。而 Eboli 等人(2020)将模糊和清晰图像先验核的逆滤波器作为预训练条件,并将其嵌入到 CNN 模型中来学习定点迭代算法中的参数,解决了图像去模糊过

程中出现的最小二乘问题。Kim等人(2022)采用多尺度失真先验模型,在恢复图像过程中利用参考模糊图像的空间信息去模糊。Quan等人(2023)利用不同大小的散焦核之间的强相关性,提出一种处理散焦模糊的去模糊算法。

4.2 盲图像去模糊

近年来,基于深度学习的图像盲去模糊技术在计算机视觉领域得到了广泛的关注(Sun等,2015; Zhang等,2020a)。相比传统方法,基于深度学习的方法直接对模糊图像进行去模糊处理,无需对模糊程度进行估计。下面分别从CNN(Nah等,2017; Cho等,2021)、RNN(Zhang等,2018; Gao等,2019)、GAN(Kupyn等,2018)和Transformer(Wang等,2022; Zamir等,2022)等4个方面对盲图像去模糊进行介绍。

4.2.1 基于卷积神经网络的方法

基于卷积神经网络的盲去模糊方法,通过多层卷积和池化操作,能够自动学习图像或模糊核的特征,生成清晰图像(Schuler等,2016)。Sun等人(2015)首次将CNN引入到盲去模糊领域,采用CNN来预测图像块水平运动模糊核的概率分布。Schuler等人(2016)则利用由粗到细的建模思想,在CNN中设计可学习层来提取局部图像特征进行核估计。然而,在未知的模糊核很大的情况下,上述方法表现并不理想。Chakrabarti(2016)采用多分辨率频率分解方法来编码输入块。他们通过频率的局部性调整初始网络层的连接方式,使得训练得到的网络能够估计较大的模糊核。Gong等人(2017)利用图像上下文信息,训练了一个全卷积深度神经网络来直接估计模糊核的运动流。Xu等人(2018)受到模糊图像边缘预测方法的启发,提出用CNN模型对模糊图像提取主要结构信息,并对其进行增强处理,来估计模糊核。Nan和Ji(2020)使用最小二乘估计器来优化模糊核估计中的误差问题,提高了模糊核估计的准确率。传统的基于MAP方法对于先验知识的依赖性较强,不能很好表征出原始图像信息。为此,Ren等人(2020)将MAP和深度模型结合,用具有跳跃连接的非对称自编码器网络生成潜在清晰图像,而用全连接网络生成模糊核。Tang等人(2023)利用未经训练的深度神经网络来表达模糊核的残差,提出了一种无监督的半盲去模糊模型。Fang等人(2023)提出一种基于隐空间先验非均匀模糊核估计

方法,利用标准化流动模型将运动模糊核空间映射为高斯分布空间,在图像隐空间内估计模糊核。

上述方法主要通过模糊核估计再进行去模糊,而CNN可通过大量的模糊图像和对应的清晰图像,学习到模糊图像和清晰图像之间的映射关系,从而避免了模糊核估计带来的误差。Nah等人(2017)和Nimish等人(2017)采用端到端方式训练了一个深层的CNN模型,可直接从模糊的输入中重建高质量的图像。Dong等人(2019)利用自然图像的多尺度冗余特性,设计了一种基于CNN模型的去噪器,去除图像模糊。通过在多个尺度上进行去模糊处理,可以更好地保留图像的细节和结构信息。针对此问题,Zhang等人(2019a)设计一个多尺度损失函数,并采用空间金字塔从粗到精地逐步恢复清晰图像。Cho等人(2021)则重新审视从粗到细的结构,提出了多输入多输出网络(multi-input multi-output UNet, MIMO-UNet)。该网络利用单个编码器接受多尺度输入图像,并使用单个解码器输出不同比例的去模糊图像。通过引入非对称特征融合机制改进了去模糊效果。Zamir等人(2021)采用编解码网络架构学习多尺度上下文信息,并利用解码端输出具有高分辨率的特点,恢复了更多图像细节信息,进一步提高了去模糊效果。

4.2.2 基于循环神经网络的方法

循环神经网络是一种能够处理序列数据的神经网络模型。在图像盲去模糊中,RNN通过对区块特征信息进行递归循环操作,将之前区块的状态信息传递给当前区块,从而学习不同区块数据之间的关系,实现去模糊过程(Zhang等,2018)。Zhang等人(2018)利用RNN的空间可变性隐式模拟去模糊过程,RNN模型在时间和空间维度上进行循环计算,逐步恢复图像的细节和结构。Tao等人(2018)提出多尺度循环去模糊网络,在不同尺度上共享网络权重,显著降低了训练复杂度。同时,通过循环模块的状态传递从而获得各尺度上的有用信息,有助于图像恢复。Gao等人(2019)关注到图像特征的尺度变化特性,在Tao等人(2018)的基础上提出参数选择性共享方法来恢复图像细节。因为多尺度提取图像特征参数量较大,Park等人(2020)采用多时态代替多尺度的方法,通过将图像分成多个小块模糊块,逐步处理原始尺度中这些模糊块来进行图像去模糊,从而减少了模型参数量。而Zhang等人(2020b)则

提出一种两阶段混合去模糊网络,用于去除真实的运动模糊。在第1阶段,使用循环编解码网络来生成循环事件。在第2阶段,将模糊图像与此循环事件连接起来作为输入,从精到粗的逐步恢复模糊图像。

4.2.3 基于生成对抗网络的方法

生成对抗网络是一种由两个神经网络组成的框架,包括生成器网络和判别器网络。在图像去模糊任务中,生成器网络将模糊图像作为输入,清晰图像作为输出。判别器网络则用来判断生成器网络输出的图像是否与真实图像一致。整个训练过程通过生成器网络和判别器网络相互对抗来优化模型参数(Kupyn等,2018)。Kupyn等人(2018)设计了一种基于生成对抗网络的单尺度去模糊网络 Deblur-GAN。其中生成器网络采用残差模块和卷积网络进行去模糊,而判别器网络则采用马尔可夫判别器进行鉴别生成图像。然而,该方法可能会出现梯度消失或爆炸的情况。Kupyn等人(2019)提出了 DeblurGAN-v2,将特征金字塔引入到生成器网络,而判别器网络采用可以评估图像全局和局部特征的相对论判别器,从而避免了梯度消失或爆炸的问题。Lu等人(2020)所采用的生成器网络包含两个编码器,其中内容编码器提取清晰和模糊图像的内容特征,而模糊编码器提取模糊信息。通过对抗性损失和周期一致性损失作为正则化器,来帮助生成器网络产生清晰图像。Zhang等人(2020a)结合了两种GAN模型,即模糊GAN和去模糊GAN,旨在减少真实模糊和合成模糊之间的差异。他们通过学习图像模糊过程来实现图像去模糊。Yang等人(2021)利用深度神经网络的深层和浅层特征来生成GAN的潜空间映射特征和噪声,以恢复模糊图像的全局结构和局部细节。大多数现有方法都是直接端到端生成清晰图像,并没有进行模糊核估计。而Li等人(2021)训练了一个模糊核判别器网络,用于分析生成的模糊核图像,并检测生成器提供不正确模糊核时可能出现的错误情况。

4.2.4 基于Transformer的方法

Transformer模型是一种基于自注意力机制和前馈神经网络的神经网络架构。自注意力机制有助于模型在处理序列时学习到不同位置之间的依赖关系,而前馈神经网络结构能够有效地捕捉到局部信息和非线性关系(Liu等,2021)。Zamir等人(2022)

提出了 Restormer 模型,将 Transformer 应用到图像去模糊任务。他们通过编解码网络实现对图像多尺度的局部和全局特征学习,更高效地处理图像的去模糊问题。Wang等人(2022)认为全局自注意力机制会增加计算复杂度,因此提出了局部增强窗口(locally-enhanced window, LeWin)Transformer 模块,更好地捕获局部上下文。同时,将 LeWin 模块应用在图像多尺度恢复框架中,利用获得的全局和局部信息来进行图像恢复。Kong等人(2023)利用频率前馈网络来确定保留图像中低频还是高频部分,从而解决了 Transformer 中使用前馈网络去模糊效果不佳的问题。Yan等人(2023)提出 Sharpformer 模型,通过 Transformer 模块直接学习图像全局特征和自适应局部特征,实现去除运动模糊。因为卷积操作有利于提取局部信息,而自注意力机制更侧重于提取全局信息。因此 Zhao(2023)设计并行的 CNN 和 Transformer 网络架构,同时提取全局和局部图像特征进行图像去模糊。

5 图像去模糊的数据集和性能评估

5.1 数据集

图像去模糊算法使用的数据集主要分为合成数据集和真实数据集。合成数据集是通过人工定义的模糊过程来生成模糊图像(Levin等,2009;Nah等,2017)。模糊过程可以是模糊核与清晰图像进行卷积或者其他模糊方式。这些数据集通常可以提供模糊图像和对应的清晰图像对,方便用于训练和评估算法的性能。而真实数据集包含真实世界中的模糊图像(Rim等,2020;Jiang等,2020)。这些图像通常是由于相机晃动、手持拍摄或其他因素导致的模糊图像。这些数据集能够更好地模拟实际场景中的图像模糊情况,对算法的鲁棒性提出更高的要求。表1详细列出了图像去模糊数据集的信息。

5.1.1 合成数据集

较早提出的合成数据集主要采用清晰图像与模糊核卷积的方法生成模糊图像。Levin等人(2009)使用4幅大小为 255×255 像素的清晰图像和8个均匀模糊核进行卷积,构建一个包含32幅模糊图像的数据集。但是Levin等人(2009)的测试图像分辨率固定在 255×255 像素,且由于图像数据较少而缺乏多样性。Sun等人(2013)通过将Sun和Hays(2012)

表 1 图像去模糊数据集
Table 1 Image deblurring datasets

数据集	参考图像/幅	模糊图像/幅	分辨率/像素	模糊核类型	失真类型	训练对/测试对
Levin 等人(2009)	4	32	255 × 255	均匀模糊	合成失真	—
Sun 等人(2013)	80	640	512 × 512	均匀模糊	合成失真	—
Köhler 等人(2012)	4	48	800 × 800	非均匀模糊	合成失真	—
Lai 等人(2016)	125	300	—	都有	都有	—
GoPro(Nah 等,2017)	3 214	3 214	1 280 × 720	非均匀模糊	合成失真	2 103/1 111
HIDE(Shen 等,2019)	8 422	8 422	1 280 × 720	非均匀模糊	合成失真	6 397/2 025
RealBlur(Rim 等,2020)	4 738	4 738	—	非均匀模糊	真实失真	3 758/980
Blur-DVS(Jiang 等,2020)	2 178	2 918	—	非均匀模糊	都有	1 782/396
ReLoBlur(Li 等,2023)	2 405	2 405	—	非均匀模糊	真实失真	2 010/395

注:“—”表示无相应数据。

的 80 幅高质量自然图像和 Levin 等人(2009)的 8 个均匀模糊核进行卷积,最终生成 640 幅模糊图像。然而,上述数据集都假设模糊核为均匀模糊,因此在该数据集上训练得到的去模糊模型难以有效解决非均匀模糊核的去模糊问题。为了模拟非均匀模糊效果,Köhler 等人(2012)记录了 6D 相机随时间的变化轨迹,并通过在机器人平台上重新播放相机的运动来生成模糊图像。他们使用 4 幅清晰图像和 12 幅摄像机运动轨迹图像进行合成,构建了一个包含 48 幅非均匀模糊图像的数据集。Lai 等人(2016)提供两个大型数据集。其中一个数据集是在不同场景下拍摄的 100 幅真实模糊图像;另外一个数据集则包含了 200 幅合成的模糊图像,其中包括非均匀模糊图像和均匀模糊图像。

为了生成更真实的模糊图像,Nah 等人(2017)使用高速摄像头 GOPRO 来快速拍摄一系列清晰图像,通过对这些间隔时间极短的图像进行求平均的方式来得到模糊图像,最终得到 GoPro 数据集。该数据集包含 2 103 对训练图像和 1 111 对测试图像。Shen 等人(2019)建立一个运动模糊数据集 HIDE(human-aware motion deblurring)。该数据集通过平均视频中的 11 个连续帧来合成模糊图像,并将中心帧作为清晰图像。HIDE 数据集包含 8 422 幅图像对,分为 6 397 对训练图像和 2 025 对测试图像。

5.1.2 真实数据集

上述数据集的图像主要通过人工合成而形成的模糊图像,对于去模糊模型在实际生活中的应用存

在一定的局限性。Rim 等人(2020)提出一个真实世界模糊图像数据集 RealBlur。该数据集由两个子集组成,一个子集是 RealBlur-R,它由相机原始图像组成;另一个子集是 RealBlur-J,它由相机处理后的 JPEG 图像组成。该数据集共包含 9 476 对图像。Jiang 等人(2020)使用 DAVIS240C 相机捕获一个大型户外数据集 Blur-DVS,包含 1 782 对训练图像和 396 对测试图像,同时还提供 740 幅真实的模糊图像。另外,Li 等人(2023)创建一个真实世界局部运动模糊数据集 ReLoBlur(real-world local motion deblurring),该数据集真实地展示了局部运动物体自身和背景产生的混叠效应,其中包含 2 010 对训练图像和 395 对测试图像。

5.2 定量评估

为了更准确地评估和分析图像去模糊任务中具有代表性的算法模型的性能,采用了第 2.2.1 节中所介绍的 PSNR 和 SSIM 两个评价指标进行衡量。PSNR 通过计算原始图像与重建图像之间的均方差来衡量图像之间的差异。而 SSIM 通过加权平均图像的亮度、对比度和结构相似度来衡量图像之间的相似性。

PSNR 越高,表示去模糊图像的质量越好。SSIM 的取值范围为 0 到 1 之间,越接近 1 表示图像结构相似度越高,重建图像质量越好。通过综合考虑 PSNR 和 SSIM 这两个评价指标,能够全面评估图像的清晰度、细节保留能力和对比度等方面的表现。表格中的实验结果是从调研的论文中获取。

5.2.1 传统图像去模糊算法性能分析

由于传统的图像非盲去模糊大多针对单个标准图像进行定性分析,而不是在数据集上进行定量分析。实验主要在早期被广泛认同的 Levin 数据集 (Levin 等, 2009) 和 Lai 数据集 (Lai 等, 2016) 上开展。Levin 数据集是一个模糊核为均匀模糊的合成数据集, 而 Lai 数据集则包含真实图像和合成图像两种类型的数据集, 实验结果如表 2 所示。

从表 2 可以看出, 非盲去模糊算法 (Krishnan 和 Fergus, 2009) 在 PSNR 和 SSIM 值上高于传统盲去模糊算法 (Cho 和 Lee, 2009; Levin 等, 2009)。这是因为非盲去模糊假设模糊核已知, 而盲去模糊需要对模糊核进行估计。一旦对模糊核估计不准确, 将导致最终去模糊效果较差。为改善此问题, 研究人员发现图像边缘信息有利于模糊核估计。Xu 和 Jia (2010) 提出对图像边缘信息进行梯度选择, 提高了模糊核估计准确性。在两个数据集上都取得明显的性能提升, 表明边缘特征提取有益于图像去模糊。基于边缘特征提取的一系列改进算法 (Sun 等, 2013; Yang 和 Ji, 2019), 从表 2 中可以看出, 其性能均有不同程度的提升。其中 Sun 等人 (2013) 的方法在 Levin 数据集上达到了传统方法的最优效果。

基于 MAP 的方法 (Chen 等, 2019; Ren 等, 2020) 通过最大化原始图像和模糊核的联合后验概率, 对

模糊图像进行估计。两个算法在 Levin 数据集上的 PSNR 和 SSIM 与 Sun 等人 (2013) 方法不相上下, 但在 Lai 数据集上明显优于 Sun 等人 (2013) 方法。

基于图像稀疏表达的方法 (Xu 等, 2013; Pan 等, 2016) 将图像的高频和低频部分分离, 可以有效地减少噪声和伪影的产生。虽然其性能指标略差于 Sun 等人 (2013) 方法, 但比之前的方法有一定程度的提升。

因为 Levin 数据集中的模糊图像都是经过均匀模糊处理后的合成图像, 而 Lai 数据集则包含真实图像和合成图像。因此, 在表 2 的实验结果中可以看出, 所有方法在 Levin 数据集上的表现优于在 Lai 数据集上的表现。尽管在 Levin 数据集上能够呈现较好的实验效果, 但实际情况下, 图像模糊往往是非均匀的, 因此模型的实用性存在一定局限性。此外, 现有传统方法大多主要针对特定失真, 无法解决 Lai 数据集中的多种失真情况, 这导致模型的泛化能力受到限制。

5.2.2 基于深度学习的图像去模糊算法性能分析

基于深度学习的方法通常需要数据集具有多样性, 以确保模型能够处理各种不同的模糊情况, 并展现出更好的泛化能力。实验主要在合成数据集 GoPro 数据集 (Nah 等, 2017)、HIDE 数据集 (Shen 等, 2019) 以及真实数据集 RealBlur 数据集 (Rim 等, 2020) 上开展。GoPro 数据集和 HIDE 数据集是常见

表 2 传统图像去模糊方法在 Levin 和 Lai 数据集上的性能
Table 2 Performance of traditional image deblurring methods on Levin and Lai datasets

算法	特征	Levin 数据集		Lai 数据集	
		PSNR/dB	SSIM	PSNR/dB	SSIM
Cho 和 Lee (2009)	基于稀疏先验的 MAP 框架盲去模糊	30.57	0.896 6	17.06	0.480 1
Levin 等人 (2009)	单独对模糊核的 MAP 估计	30.80	0.909 2	—	—
Krishnan 和 Fergus (2009)	基于超拉普拉斯先验的非盲去模糊	31.06	0.900 6	18.73	0.501 0
Xu 和 Jia (2010)	梯度选择衡量图像边缘信息	31.67	0.916 3	20.18	0.708 0
Xu 等人 (2013)	不依赖边缘检测的高稀疏去模糊框架	31.87	0.924 3	19.23	0.659 3
Sun 等人 (2013)	基于块先验的模糊核估计方法	32.99	0.933 0	20.48	0.656 2
Pan 等人 (2016)	采用暗通道信息进行去模糊	32.69	0.928 4	19.89	0.665 6
Chen 等人 (2019)	基于半二次分裂策略和从粗到细 MAP 框架	31.73	0.923 6	—	—
Yang 和 Ji (2019)	基于变分贝叶斯推理的边缘选择算法	32.04	0.912 0	21.79	0.704 0
Ren 等人 (2020)	联合优化清晰图像和模糊核解决 MAP 问题	33.01	0.931 3	21.13	0.731 9

注: 加粗字体表示各列最优结果; “—” 表示对应文献无相应数据。

的图像去模糊合成数据集,它们通过平均视频中连续帧来合成模糊。RealBlur数据集包含由相机原始图像组成 RealBlur-R 和相机处理后的 JPEG 图像组成 RealBlur-J。实验结果如表 3 所示。

表 3 基于深度学习图像去模糊方法在 GoPro 和 HIDE 数据集上的性能
Table 3 Performance of some deep learning-based image deblurring methods on GoPro and HIDE datasets

网络架构	算法	GoPro		HIDE		RealBlur-R		RealBlur-J	
		PSNR/dB	SSIM	PSNR/dB	SSIM	PSNR/dB	SSIM	PSNR/dB	SSIM
CNN	Sun 等人(2015)	24.64	0.843	23.21	0.797	—	—	—	—
	DeepDeblur(Nah 等,2017)	29.08	0.914	25.73	0.874	32.51	0.841	27.87	0.827
	DMPHN(Zhang 等,2019a)	31.20	0.94	29.09	0.924	—	—	—	—
	MIMO-Unet(Cho 等,2021)	32.45	0.957	29.99	0.93	35.54	0.947	27.63	0.837
	MPRNet(Zamir 等,2021)	32.66	0.959	30.96	0.939	35.99	0.952	28.7	0.873
RNN	SRN(Tao 等,2018)	30.26	0.934	28.36	0.915	35.66	0.947	28.56	0.867
	DSD(Gao 等,2019)	30.92	0.935	29.11	0.913	—	—	—	—
GAN	DeblurGan(Kupyn 等,2018)	28.70	0.858	24.51	0.871	33.79	0.903	27.97	0.834
	DeblurGan-v2(Kupyn 等,2019)	29.55	0.934	26.61	0.875	35.26	0.944	28.7	0.866
	DBGAN(Zhang 等,2020a)	31.10	0.942	28.94	0.915	33.78	0.909	24.93	0.745
Transformer	Restormer(Zamir 等,2022)	32.92	0.961	31.22	0.942	36.19	0.957	28.96	0.879
	FSAS(Kong 等,2023)	34.21	0.969	31.62	0.946	40.11	0.973 2	32.62	0.933
	CTMS(Zhao 等,2023)	32.73	0.959	31.05	0.94	—	—	27.18	0.883

注:加粗字体表示各列最优结果;“—”表示对应文献无相应数据。

Sun 等人(2015)较早将 CNN 应用在图像去模糊领域。尽管其在 GoPro 和 HIDE 数据上的效果并不突出,但展现了深度学习在图像去模糊领域的巨大潜力。后续研究中,DeepDeblur 和 DMPHN 对骨干网络进行改进。与 Sun 等人(2015)方法相比,它们在合成数据集上的 PSNR 和 SSIM 都取得了显著提升,尤其是 DMPHN 在 HIDE 数据集上显示出较好的性能。随着深度学习快速发展,端到端的去模糊方法 MPRNet(multi-stage progressive image restoration network)和 MIMO-Unet 在合成数据集上表现出色,其 PSNR 超过了 30 dB。此外,在真实数据集 RealBlur 上也展现出令人满意的效果。

从表 3 可以看出,基于 RNN 的 SRN 和 DSD(dynamic scene deblurring)方法相比同一时段提出的方法,在合成模糊和真实模糊上都表现出非常好的性能,其 PSNR 和 SSIM 指标都高于其他方法。


基于 GAN 设计的 DeblurGan 方法虽然其在合成数据集上性能指标略逊于 DeepDeblur,但在 Real-

Blur 数据集上表现更优。而且其改进算法 DeblurGan-v2 和 DBGAN(DeBlur GAN)的性能在 2 个合成数据集上的 PSNR 和 SSIM 与基于 RNN 的方法不相上下,但在 RealBlur 数据集上表现欠缺。

Transformer 模型能够建立全局依赖关系,并有效地捕捉到整个图像的上下文信息。因此,近期提出的 Restormer、FSAS(frequency-domain-based self-attention solver)和 CTMS 等算法都是基于 Transformer 模型。在 GoPro 数据集上,它们的 PSNR 和 SSIM 指标都分别达到了 32 dB 和 0.96,在 HIDE 数据集上,也远超其他算法。即便在真实数据集 RealBlur 上,也表现出优秀的实验效果,进一步展现 Transformer 模型在图像去模糊领域具有巨大潜力。

5.3 定性评估

图 3 和图 4 分别展示了传统方法和基于深度学习方法在图像去模糊任务上的可视化结果,并选择了两个代表性的场景以展示不同去模糊算法之间的差异。




(a) 模糊图像 (b) Cho和Lee (2009) (c) Xu和Jia (2010) (d) Xu等人 (2013) (e) Yang和Ji (2019)

图3 传统方法定性比较结果(Yang 和 Ji, 2019)

Fig. 3 Qualitative comparisons of traditional methods (Yang and Ji, 2019)

((a) blurred images; (b) Cho and Lee (2009); (c) Xu and Jia (2010); (d) Xu et al. (2013); (e) Yang and Ji (2019))



(a) 模糊图像 (b) 参考图像 (c) DeepDeblur (d) SRN (e) DBGAN (f) MPRNet (g) CTMS

图4 深度学习方法定性比较结果(Zhao 等, 2023)

Fig. 4 Qualitative comparisons of deep learning methods(Zhao et al. , 2023)

((a) blurred images; (b) reference images; (c) DeepDeblur; (d) SRN; (e) DBGAN; (f) MPRNet; (g) CTMS)

图3展示了传统图像去模糊方法的可视化结果(Yang 和 Ji, 2019)。尽管各个算法采用了不同的方法,但在图像去模糊上均呈现出令人满意的效果。其中,基于图像边缘特征去除图像模糊的方法(Xu 和 Jia, 2010; Yang 和 Ji, 2019)更注重保留图像的纹理细节;基于最大后验概率的方法(Cho 和 Lee, 2009)通过引入正则化项成功地避免了图像过度锐化和噪声放大等问题;而基于图像稀疏表达的方法(Xu 等, 2013)能有效地分离图像的高频和低频部分,从而减少了噪声和伪影的产生。

基于深度学习的图像去模糊方法可视化结果如图4所示(Zhao 等, 2023)。通过对比以下几种不同的方法:基于CNN的Deepdeblur(Nah 等, 2017)和

MPRNet(Zamir 等, 2021)方法,基于RNN的SRN(Tao 等, 2018)方法,基于GAN的DBGAN(Zhang 等, 2020a)方法和基于Transformer的CTMS(Zhao 等, 2023)方法。可以观察到,不仅模型架构不同对去模糊结果会产生影响,即使采用相似网络结构的方法,如Deepdeblur和MPRNet,也会产生不同的结果。值得特别关注的是,基于Transformer的CTMS方法在图像去模糊的效果上表现最为出色。

5.4 运行效率

在基于深度学习的图像去模糊算法中,通常选取平均运行时间和模型参数量作为衡量模型效率的重要指标(Cho 等, 2021)。选取了不同网络架构中具有代表性的算法,并统计它们在GoPro数据集测

试集上完成图像去模糊所需的平均运行时间和模型参数量,结果如表4所示。结果表明,大部分算法的平均运行时间都在1 s内,但部分模型的参数量相对较大。因此,选择算法时需要综合考虑这两个指标,以确保模型在实际应用中能够取得良好的性能表现并满足资源消耗的限制。但是如何平衡平均运行时间和模型参数量仍需要进一步的研究和探索,以提高图像去模糊算法的效率和性能。

表4 不同算法的运行效率

Table 4 Running efficiency of representative methods

算法	参数量/M	平均运行时间/s
DMPHN(Zhang等,2019a)	21.7	0.04
MIMO-Unet(Cho等,2021)	16.1	0.02
MPRNet(Zamir等,2021)	20.1	0.09
DSD(Gao等,2019)	14.7	1.60
DeblurGan-v2(Kupyn等,2019)	60.9	0.04
DBGAN(Zhang等,2020a)	11.6	0.06
Restormer(Zamir等,2022)	26.1	0.08
FSAS(Kong等,2023)	16.6	0.13
CTMS(Zhao等,2023)	16.5	0.12

注:加粗字体表示各列最优结果。

6 结 语

传统的图像去模糊方法从去噪、迭代优化、图像边缘信息和稀疏表达等方面展开研究,提出了许多优秀的算法。然而,这些传统方法需要人工选择特征,并且大多针对某种情况下的模糊,因此其泛化能力受到一定限制。而随着深度学习技术的不断进步,基于深度学习的各类图像去模糊算法不断涌现,不仅在性能上逐渐超越了传统方法,而且能够更好地适应各种模糊环境。

尽管深度学习方法在图像去模糊领域取得了巨大进展,但仍存在一些严峻挑战和难题:

1)全面的评估指标。目前在图像去模糊领域中最广泛使用的评价指标是PSNR和SSIM。PSNR仅衡量恢复图像和原始图像之间的均方误差,无法反映图像细节和清晰度等方面的质量。同时,PSNR对

于人眼感知不敏感,可能导致PSNR高但视觉效果差的情况。而SSIM虽然可以反映图像的结构信息和视觉质量,但对于图像亮度和对比度的变化并不敏感。因此,在评估模型时,需要考虑基于人眼视觉特性的感知质量评价指标。然而,这需要大量的主观评价数据和人力资源,并且还会受评价者个体差异影响。因此,要获得与人眼视觉特性相一致的评价指标仍面临挑战。

2)模型的泛化性和数据集。在图像去模糊领域,模型需要具备处理各种复杂模糊情况的能力,包括散焦模糊、高斯模糊和运动模糊等。但是,由于这些模糊成因的复杂性,训练出能够应对所有情况的模型是一项具有挑战性的任务。同时,去模糊数据集通常需要大量的真实图像和对应的模糊图像,以便训练出能够对各种不同模糊情况进行处理的模型。但是,由于获取真实图像和对应的模糊图像需要大量的时间和人力成本。因此,构建大量高质量的数据集也是一项重要且具有挑战性的任务。

3)模型的效率问题。由于现在移动拍摄设备的捕获的图像具有超高分辨率,但很多图像去模糊模型在处理高分辨率图像时表现不佳或者需要长时间的计算,使得在实际应用中带来了困扰。尽管基于深度学习的图像去模糊方法相对传统方法有更好的性能,但也伴随着参数量大的问题。因此,如何开发出高效的轻量化去模糊算法还需要付出大量的努力。

图像去模糊技术至今仍面临众多挑战,需要不断研究与改进,从而提升其质量和应用领域的广度。同时,综合考虑评估指标、模型的泛化能力、数据的多样性和数量等因素,能更好地在实际中应用图像去模糊技术。

参考文献(References)

- Bar L, Kiryati N and Sochen N. 2006. Image deblurring in the presence of impulsive noise. *International Journal of Computer Vision*, 70 (3): 279-298 [DOI: 10.1007/s11263-006-6468-1]
- Chakrabarti A. 2016. A neural approach to blind motion deblurring//*Proceedings of the 14th European Conference on Computer Vision (ECCV)*. Amsterdam, The Netherlands: Springer: 221-235 [DOI: 10.1007/978-3-319-46487-9_14]
- Chandler D M and Hemami S S. 2007. VSNR: a wavelet-based visual signal-to-noise ratio for natural images. *IEEE Transactions on*

- Image Processing, 16(9): 2284-2298 [DOI: 10.1109/TIP.2007.901820]
- Chen F, Huang X J and Chen W F. 2010. Texture-preserving image deblurring. IEEE Signal Processing Letters, 17(12): 1018-1021 [DOI: 10.1109/LSP.2010.2078807]
- Chen F and Ma J L. 2009. An empirical identification method of gaussian blur parameter for image deblurring. IEEE Transactions on Signal Processing, 57(7): 2467-2478 [DOI: 10.1109/TSP.2009.2018358]
- Chen G H, Yang C L and Xie S L. 2006. Gradient-based structural similarity for image quality assessment//Proceedings of 2006 International Conference on Image Processing. Atlanta, USA: IEEE: 2929-2932 [DOI: 10.1109/ICIP.2006.313132]
- Chen L, Fang F M, Wang T T and Zhang G X. 2019. Blind image deblurring with local maximum gradient prior//Proceedings of 2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Long Beach, USA: IEEE: 1742-1750 [DOI: 10.1109/CVPR.2019.00184]
- Cheng R Q, Yu Y, Shi D Z and Cai W. 2022. The critical review of image and video quality assessment methods. Journal of Image and Graphics, 27(5): 1410-1429 (程茹秋, 余烨, 石岱宗, 蔡文. 2022. 图像与视频质量评价综述. 中国图象图形学报, 27(5): 1410-1429) [DOI: 10.11834/jig.210314]
- Cho S and Lee S. 2009. Fast motion deblurring. ACM Transactions on Graphics, 28(5): 1-8 [DOI: 10.1145/1618452.161849]
- Cho S J, Ji S W, Hong J P, Jung S W and Ko S J. 2021. Rethinking coarse-to-fine approach in single image deblurring//Proceedings of 2021 IEEE/CVF International Conference on Computer Vision (ICCV). Montreal, Canada: IEEE: 4621-4630 [DOI: 10.1109/ICCV.2021.00460]
- Dabov K, Foi A, Katkovnik V and Egiazarian K. 2007. Image denoising by sparse 3D transform-domain collaborative filtering. IEEE Transactions on Image Processing, 16(8): 2080-2095 [DOI: 10.1109/TIP.2007.901238]
- Dai S Y and Wu Y. 2008. Motion from blur//Proceedings of 2008 IEEE Conference on Computer Vision and Pattern Recognition. Anchorage, USA: IEEE: 769-777 [DOI: 10.1109/CVPR.2008.4587582]
- Danielyan A, Katkovnik V and Egiazarian K. 2012. BM3D frames and variational image deblurring. IEEE Transactions on Image Processing, 21(4): 1715-1728 [DOI: 10.1109/TIP.2011.2176954]
- Dong J X, Roth S and Schiele B. 2021. Learning spatially-variant MAP models for non-blind image deblurring//Proceedings of 2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Nashville, USA: IEEE: 4884-4893 [DOI: 10.1109/CVPR46437.2021.00485]
- Dong J X, Roth S and Schiele B. 2022. DWDN: deep wiener deconvolution network for non-blind image deblurring. IEEE Transactions on Pattern Analysis and Machine Intelligence, 44(12): 9960-9976 [DOI: 10.1109/TPAMI.2021.3138787]
- Dong W S, Wang P Y, Yin W T, Shi G M, Wu F F and Lu X T. 2019. Denoising prior driven deep neural network for image restoration. IEEE Transactions on Pattern Analysis and Machine Intelligence, 41(10): 2305-2318 [DOI: 10.1109/TPAMI.2018.2873610]
- Donoho D L. 2006. Compressed sensing. IEEE Transactions on Information Theory, 52(4): 1289-1306 [DOI: 10.1109/TIT.2006.871582]
- Eboli T, Sun J and Ponce J. 2020. End-to-end interpretable learning of non-blind image deblurring//Proceedings of the 16th European Conference on Computer Vision (ECCV). Glasgow, UK: Springer: 314-331 [DOI: 10.1007/978-3-030-58520-4_19]
- Fang Y M, Sui X J, Yan J B, Liu X L and Huang L P. 2021. Progress in no-reference image quality assessment. Journal of Image and Graphics, 26(2): 265-286 (方玉明, 眭相杰, 鄢杰斌, 刘学林, 黄丽萍. 2021. 无参考图像质量评价研究进展. 中国图象图形学报, 26(2): 265-286) [DOI: 10.11834/jig.200274]
- Fang Z X, Wu F F, Dong W S, Li X, Wu J J and Shi G M. 2023. Self-supervised non-uniform kernel estimation with flow-based motion prior for blind image deblurring//Proceedings of 2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Vancouver, Canada: IEEE: 18105-18114 [DOI: 10.1109/CVPR52729.2023.01736]
- Fergus R, Singh B, Hertzmann A, Roweis S T and Freeman W T. 2006. Removing camera shake from a single photograph. ACM Transactions on Graphics, 25(3): 787-794 [DOI: 10.1145/1141911.1141956]
- Gao H Y, Tao X, Shen X Y and Jia J Y. 2019. Dynamic scene deblurring with parameter selective sharing and nested skip connections//Proceedings of 2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Long Beach, USA: IEEE: 3843-3851 [DOI: 10.1109/CVPR.2019.00397]
- Gong D, Yang J, Liu L Q, Zhang Y N, Reid I, Shen C H, van den Hengel A and Shi Q F. 2017. From motion blur to motion flow: a deep learning solution for removing heterogeneous motion blur//Proceedings of 2017 IEEE Conference on Computer Vision and Pattern Recognition. Honolulu, USA: IEEE: 3806-3815 [DOI: 10.1109/CVPR.2017.405]
- Haigh J. 1980. Introduction to the theory of nonparametric statistics. Journal of the Royal Statistical Society: Series A (General), 143(3): 376-377 [DOI: 10.2307/2982149]
- He K M, Zhang X Y, Ren S Q and Sun J. 2016. Deep residual learning for image recognition//Proceedings of 2016 IEEE Conference on Computer Vision and Pattern Recognition. Las Vegas, USA: IEEE: 770-778 [DOI: 10.1109/CVPR.2016.90]
- Heng H J, Ye H B, Zhou M and Huang R. 2021. Coarse-to-fine multi-scale defocus blur detection. Journal of Image and Graphics, 26(3): 581-593 (衡红军, 叶何斌, 周末, 黄睿. 2021. 由粗到精的多尺度散焦模糊检测. 中国图象图形学报, 26(3): 581-593)

- [DOI: 10.11834/jig.200126]
- Hoßfeld T, Heegaard P E, Varela M and Möller S. 2016. QoE beyond the MOS: an in-depth look at QoE via better metrics and their relation to MOS. *Quality and User Experience*, 1(1): # 2 [DOI: 10.1007/s41233-016-0002-1]
- Huynh-Thu Q and Ghanbari M. 2008. Scope of validity of PSNR in image/video quality assessment. *Electronics Letters*, 44(13): 800-801 [DOI: 10.1049/el:20080522]
- Isola P, Zhu J Y, Zhou T H and Efros A A. 2017. Image-to-image translation with conditional adversarial networks//*Proceedings of 2017 IEEE Conference on Computer Vision and Pattern Recognition*. Honolulu, USA: IEEE: 5967-5976 [DOI: 10.1109/CVPR.2017.632]
- Jia J Y. 2007. Single Image motion deblurring using transparency//*Proceedings of 2007 IEEE Conference on Computer Vision and Pattern Recognition*. Minneapolis, USA: IEEE: 1-8 [DOI: 10.1109/CVPR.2007.383029]
- Jiang Z, Zhang Y, Zou D Q, Ren J, Lv J C and Liu Y B. 2020. Learning event-based motion deblurring//*Proceedings of 2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition*. Seattle, USA: IEEE: 3317-3326 [DOI: 10.1109/CVPR42600.2020.00338]
- Joshi N, Szeliski R and Kriegman D J. 2008. PSF estimation using sharp edge prediction//*Proceedings of 2008 IEEE Conference on Computer Vision and Pattern Recognition*. Anchorage, USA: IEEE: 1-8 [DOI: 10.1109/CVPR.2008.4587834]
- Kalifa J, Mallat S and Rouge B. 2003. Deconvolution by thresholding in mirror wavelet bases. *IEEE Transactions on Image Processing*, 12(4): 446-457 [DOI: 10.1109/TIP.2003.810592]
- Kang L, Ye P, Li Y and Doermann D. 2014. Convolutional neural networks for no-reference image quality assessment//*Proceedings of 2014 IEEE Conference on Computer Vision and Pattern Recognition*. Columbus, USA: IEEE: 1733-1740 [DOI: 10.1109/CVPR.2014.224]
- Kheradmand A and Milanfar P. 2014. A general framework for regularized, similarity-based image restoration. *IEEE Transactions on Image Processing*, 23(12): 5136-5151 [DOI: 10.1109/TIP.2014.2362059]
- Khetkeeree S and Liangrocapart S. 2019. Image restoration using optimized weiner filtering based on modified tikhonov regularization//*Proceedings of 2019 IEEE 4th International Conference on Signal and Image Processing (ICSIP)*. Wuxi, China: IEEE: 1015-1020 [DOI: 10.1109/SIPROCESS.2019.8868907]
- Kim I, Lim D, Seo Y, Lee J, Choi W and Song S. 2022. Image deblurring using deep multi-scale distortion prior//*Proceedings of 2022 IEEE International Conference on Image Processing (ICIP)*. Bordeaux, France: IEEE: 446-450 [DOI: 10.1109/ICIP46576.2022.9897621]
- Köhler R, Hirsch M, Mohler B, Schölkopf B and Harmeling S. 2012. Recording and playback of camera shake: benchmarking blind deconvolution with a real-world database//*Proceedings of the 12th European Conference on Computer Vision (ECCV)*. Florence, Italy: Springer: 27-40 [DOI: 10.1007/978-3-642-33786-4_3]
- Kong L S, Dong J X, Ge J J, Li M Q and Pan J S. 2023. Efficient frequency domain-based transformers for high-quality image deblurring//*Proceedings of 2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition*. Vancouver, Canada: IEEE: 5886-5895 [DOI: 10.1109/CVPR52729.2023.00570]
- Krishnan D and Fergus R. 2009. Fast image deconvolution using hyper-Laplacian priors//*Proceedings of the 22nd International Conference on Neural Information Processing Systems*. Vancouver, Canada: Curran Associates Inc.: 1033-1041 [DOI: 10.5555/2984093.2984210]
- Krishnan D, Tay T and Fergus R. 2011. Blind deconvolution using a normalized sparsity measure//*Proceedings of 2011 IEEE Conference on Computer Vision and Pattern Recognition*. Colorado Springs, USA: IEEE: 233-240 [DOI: 10.1109/CVPR.2011.5995521]
- Kupyn O, Budzan V, Mykhailych M, Mishkin D and Matas J. 2018. DeblurGAN: blind motion deblurring using conditional adversarial networks//*Proceedings of 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition*. Salt Lake City, USA: IEEE: 8183-8192 [DOI: 10.1109/CVPR.2018.00854]
- Kupyn O, Martyniuk T, Wu J R and Wang Z Y. 2019. DeblurGAN-v2: deblurring (orders-of-magnitude) faster and better//*Proceedings of 2019 IEEE/CVF International Conference on Computer Vision*. Seoul, Korea (South): IEEE: 8877-8886 [DOI: 10.1109/ICCV.2019.00897]
- Lai W S, Huang J B, Hu Z, Ahuja N and Yang M H. 2016. A comparative study for single image blind deblurring//*Proceedings of 2016 IEEE Conference on Computer Vision and Pattern Recognition*. Las Vegas, USA: IEEE: 1701-1709 [DOI: 10.1109/CVPR.2016.188]
- Lanza A, Morigi S and Sgallari F. 2016. Convex image denoising via non-convex regularization with parameter selection. *Journal of Mathematical Imaging and Vision*, 56(2): 195-220 [DOI: 10.1007/s10851-016-0655-7]
- Larson E C and Chandler D M. 2010. Most apparent distortion: full-reference image quality assessment and the role of strategy. *Journal of Electronic Imaging*, 19(1): #011006 [DOI: 10.1117/1.3267105]
- Levin A, Weiss Y, Durand F and Freeman W T. 2009. Understanding and evaluating blind deconvolution algorithms//*Proceedings of 2009 IEEE Conference on Computer Vision and Pattern Recognition*. Miami, USA: IEEE: 1964-1971 [DOI: 10.1109/CVPR.2009.5206815]
- Levin A, Weiss Y, Durand F and Freeman W T. 2011. Efficient marginal likelihood optimization in blind deconvolution//*Proceedings of*

- 2011 IEEE Conference on Computer Vision and Pattern Recognition. Colorado Springs, USA: IEEE: 2657-2664 [DOI: 10.1109/CVPR.2011.5995308]
- Li H Y, Zhang Z R, Jiang T T, Luo P, Feng H J and Xu Z H. 2023. Real-world deep local motion deblurring// Proceedings of the 37th AAAI Conference on Artificial Intelligence. Washington, USA: AAAI: 1314-1322 [DOI: 10.1609/aaai.v37i1.25215]
- Li Q and Wang Z. 2009. Reduced-reference image quality assessment using divisive normalization-based image representation. IEEE Journal of Selected Topics in Signal Processing, 3 (2) : 202-211 [DOI: 10.1109/JSTSP.2009.2014497]
- Li X L, Li G and Du Z L. 2021. High fidelity single image blind deblur via GAN. Wireless Networks [DOI: 10.1007/s11276-020-02496-9]
- Li Y M, Po L M, Feng L T and Yuan F. 2016. No-reference image quality assessment with deep convolutional neural networks//Proceeding of 2016 IEEE International Conference on Digital Signal Processing. Beijing, China: IEEE: 685-689 [DOI: 10.1109/ICDSP.2016.7868646]
- Liu L P, Sun J and Gao S Y. 2022. Overview of blind deblurring methods for single image. Journal of Frontiers of Computer Science and Technology, 16(3) : 552-564 (刘利平, 孙建, 高世妍. 2022. 单图像盲去模糊方法概述. 计算机科学与探索, 16(3) : 552-564) [DOI: 10.3778/j.issn.1673-9418.2019.2106100]
- Liu Y T, Zhai G T, Gu K, Liu X M, Zhao D B and Gao W. 2018. Reduced-reference image quality assessment in free-energy principle and sparse representation. IEEE Transactions on Multimedia, 20(2) : 379-391 [DOI: 10.1109/TMM.2017.2729020]
- Liu Z, Lin Y T, Cao Y, Hu H, Wei Y X, Zhang Z, Lin S and Guo B N. 2021. Swin Transformer: hierarchical vision Transformer using shifted windows//Proceedings of 2021 IEEE/CVF International Conference on Computer Vision. Montreal, Canada: IEEE: 9992-10002 [DOI: 10.1109/ICCV48922.2021.00986]
- Lu B Y, Chen J C and Chellappa R. 2020. UID-GAN: unsupervised image deblurring via disentangled representations. IEEE Transactions on Biometrics, Behavior, and Identity Science, 2(1) : 26-39 [DOI: 10.1109/TBIOM.2019.2959133]
- Lucy L B. 1974. An iterative technique for the rectification of observed distributions. The Astronomical Journal, 79 (6) : 745-754 [DOI: 10.1086/111605]
- Ma S X, Wang J X, Dai Y S, Chen J and Shao W Z. 2019. Deblurring and recognition of blurred license plates in surveillance video. Information System Engineering, (11) : 111-113 (马苏欣, 王家希, 戴雅淑, 陈杰, 邵文泽. 2019. 监控视频下模糊车牌的去模糊与识别探析. 信息系统工程, (11) : 111-113) [DOI: 10.3969/j.issn.1001-2362.2019.11.046]
- Madhusudana P C, Birkbeck N, Wang Y L, Adsumilli B and Bovik A C. 2022. Image quality assessment using contrastive learning. IEEE Transactions on Image Processing, 31 : 4149-4161 [DOI: 10.1109/TIP.2022.3181496]
- Mittal A, Moorthy A K and Bovik A C. 2012. No-reference image quality assessment in the spatial domain. IEEE Transactions on Image Processing, 21(12) : 4695-4708 [DOI: 10.1109/TIP.2012.2214050]
- Moorthy A K and Bovik A C. 2011. Blind image quality assessment: from natural scene statistics to perceptual quality. IEEE Transactions on Image Processing, 20(12) : 3350-3364 [DOI: 10.1109/TIP.2011.2147325]
- Mosleh A, Sola Y E, Zargari F, Onzon E and Langlois J M P. 2018. Explicit ringing removal in image deblurring. IEEE Transactions on Image Processing, 27 (2) : 580-593 [DOI: 10.1109/TIP.2017.2764625]
- Nah S, Kim T H and Lee K M. 2017. Deep multi-scale convolutional neural network for dynamic scene deblurring//Proceedings of 2017 IEEE Conference on Computer Vision and Pattern Recognition. Honolulu, USA: IEEE: 257-265 [DOI: 10.1109/CVPR.2017.35]
- Nan Y S and Ji H. 2020. Deep learning for handling kernel/model uncertainty in image deconvolution//Proceedings of 2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Seattle, USA: IEEE: 2385-2394 [DOI: 10.1109/CVPR42600.2020.00246]
- Nimisha T M, Singh A K and Rajagopalan A N. 2017. Blur-invariant deep learning for blind-deblurring//Proceedings of 2017 IEEE International Conference on Computer Vision (ICCV). Venice, Italy: IEEE: 4762-4770 [DOI: 10.1109/ICCV.2017.509]
- Pan J S and Su Z X. 2013. Fast ℓ^0 -regularized kernel estimation for robust motion deblurring. IEEE Signal Processing Letters, 20(9) : 841-844 [DOI: 10.1109/LSP.2013.2261986]
- Pan J S, Sun D Q, Pfister H and Yang M H. 2016. Blind image deblurring using dark channel prior//Proceedings of 2016 IEEE Conference on Computer Vision and Pattern Recognition. Las Vegas, USA: IEEE: 1628-1636 [DOI: 10.1109/CVPR.2016.180]
- Park D, Kang D U, Kim J and Chun S Y. 2020. Multi-temporal recurrent neural networks for progressive non-uniform single image deblurring with incremental temporal training//Proceedings of the 16th European Conference on Computer Vision (ECCV). Glasgow, UK: Springer: 327-343 [DOI: 10.1007/978-3-030-58539-6_20]
- Quan Y H, Wu Z C and Ji H. 2023. Neumann network with recursive kernels for single image defocus deblurring//Proceedings of 2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Vancouver, Canada: IEEE: 5754-5763 [DOI: 10.1109/CVPR52729.2023.00557]
- Ren D W, Zhang K, Wang Q L, Hu Q H and Zuo W M. 2020. Neural blind deconvolution using deep priors//Proceedings of 2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Seattle, USA: IEEE: 3338-3347 [DOI: 10.1109/CVPR.42600.2020.00340]
- Rim J, Lee H, Won J and Cho S. 2020. Real-world blur dataset for

- learning and benchmarking deblurring algorithms//Proceedings of the 16th European Conference on Computer Vision (ECCV). Glasgow, UK: Springer: 184-201 [DOI: 10.1007/978-3-030-58595-2_12]
- Schmidt U and Roth S. 2014. Shrinkage fields for effective image restoration//Proceedings of 2014 IEEE Conference on Computer Vision and Pattern Recognition. Columbus, USA: IEEE: 2774-2781 [DOI: 10.1109/CVPR.2014.349]
- Schmidt U, Rother C, Nowozin S, Jancsary J and Roth S. 2013. Discriminative non-blind deblurring//Proceedings of 2013 IEEE Conference on Computer Vision and Pattern Recognition. Portland, USA: IEEE: 604-611 [DOI: 10.1109/CVPR.2013.84]
- Schuler C J, Burger H C, Harmeling S and Schölkopf B. 2013. A machine learning approach for non-blind image deconvolution//Proceedings of 2013 IEEE Conference on Computer Vision and Pattern Recognition. Portland, USA: IEEE: 1067-1074 [DOI: 10.1109/CVPR.2013.142]
- Schuler C J, Hirsch M, Harmeling S and Schölkopf B. 2016. Learning to Deblur. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 38 (7) : 1439-1451 [DOI: 10.1109/TPAMI.2015.2481418]
- Shan Q, Jia J Y and Agarwala A. 2008. High-quality motion deblurring from a single image. *ACM Transactions on Graphics*, 27(3) : 1-10 [DOI: 10.1145/1360612.1360672]
- Sharif S M A, Naqvi R A, Mehmood Z, Hussain J, Ali A and Lee S W. 2023. MedDeblur: medical image deblurring with residual dense spatial-asymmetric attention. *Mathematics*, 11 (1) : #115 [DOI: 10.3390/math11010115]
- Shen C T, Hwang W L and Pei S C. 2012. Spatially-varying out-of-focus image deblurring with L1-2 optimization and a guided blur map//Proceedings of 2012 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). Kyoto, Japan: IEEE: 1069-1072 [DOI: 10.1109/ICASSP.2012.6288071]
- Shen Z Y, Wang W G, Lu X K, Shen J B, Lin H B, Xu T F and Shao L. 2019. Human-aware motion deblurring//Proceedings of 2019 IEEE/CVF International Conference on Computer Vision. Seoul, Korea (South) : IEEE: 5571-5580 [DOI: 10.1109/ICCV.2019.00567]
- Sun J, Cao W F, Xu Z B and Ponce J. 2015. Learning a convolutional neural network for non-uniform motion blur removal//Proceedings of 2015 IEEE Conference on Computer Vision and Pattern Recognition. Boston, USA: IEEE: 769-777 [DOI: 10.1109/CVPR.2015.7298677]
- Sun L B, Cho S, Wang J and Hays J. 2013. Edge-based blur kernel estimation using patch priors//Proceedings of 2013 IEEE International Conference on Computational Photography (ICCP). Cambridge, USA: IEEE: 1-8 [DOI: 10.1109/ICCPHOT.2013.6528301]
- Sun L B and Hays J. 2012. Super-resolution from internet-scale scene matching//Proceedings of 2012 IEEE International Conference on Computational Photography (ICCP). Seattle, USA: IEEE: 1-12 [DOI: 10.1109/ICCPHOT.2012.6215221]
- Tang H P, Zeng X J, Niu S J, Chen Q and Sun Q S. 2015. Remote sensing image multi-scale deblurring based on regularization constraint. *Journal of Image and Graphics*, 20(3) : 386-394 (谭海鹏, 曾炫杰, 牛四杰, 陈强, 孙权森. 2015. 基于正则化约束的遥感图像多尺度去模糊. *中国图象图形学报*, 20(3) : 386-394) [DOI: 10.11834/jig.20150310]
- Tang X L, Zhao X L, Liu J, Wang J L, Miao Y C and Zeng T Y. 2023. Uncertainty-aware unsupervised image deblurring with deep residual prior//Proceedings of 2023 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR). Vancouver, Canada: IEEE: 9883-9892 [DOI: 10.1109/CVPR52729.2023.00953]
- Tao X, Gao H Y, Shen X Y, Wang J and Jia J Y. 2018. Scale-recurrent network for deep image deblurring//Proceedings of 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Salt Lake City, USA: IEEE: 8174-8182 [DOI: 10.1109/CVPR.2018.00853]
- Vasu S, Maligireddy V R and Rajagopalan A N. 2018. Non-blind deblurring: handling kernel uncertainty with CNNs//Proceedings of 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition. Salt Lake City, USA: IEEE: 3272-3281 [DOI: 10.1109/CVPR.2018.00345]
- Wan Z L, Gu K and Zhao D B. 2020. Reduced reference stereoscopic image quality assessment using sparse representation and natural scene statistics. *IEEE Transactions on Multimedia*, 22(8) : 2024-2037 [DOI: 10.1109/TMM.2019.2950533]
- Wang L, Luo S W and Wang Z. 2010. Image deblur with regularized backward heat diffusion//Proceedings of 2010 IEEE International Conference on Image Processing (ICIP). Hong Kong, China: IEEE: 1141-1144 [DOI: 10.1109/ICIP.2010.5651365]
- Wang S G, Deng C W, Lin W S, Huang G B and Zhao B J. 2017. NMF-based image quality assessment using extreme learning machine. *IEEE Transactions on Cybernetics*, 47(1) : 232-243 [DOI: 10.1109/TCYB.2015.2512852]
- Wang Z, Bovik A C, Sheikh H R and Simoncelli E P. 2004. Image quality qssessment: from error visibility to structural similarity. *IEEE Transactions on Image Processing*, 13(4) : 600-612 [DOI: 10.1109/TIP.2003.819861]
- Wang Z, Wu G X, Sheikh H R, Simoncelli E P, Yang E H and Bovik A C. 2006. Quality-aware images. *IEEE Transactions on Image Processing*, 15(6) : 1680-1689 [DOI: 10.1109/TIP.2005.864165]
- Wang Z D, Cun X, Bao J M, Zhou W G, Liu J Z and Li H Q. 2022. Uformer: a general U-shaped transformer for image restoration//Proceedings of 2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition. New Orleans, USA: IEEE: 17662-17672 [DOI: 10.1109/CVPR52688.2022.01716]

- Wiener N. 1964. *Extrapolation, Interpolation, and Smoothing of Stationary Time Series: with Engineering Applications*. New York: The MIT Press
- Xie S P, Zheng X Y, Shao W Z, Zhang Y D, Lv T X and Li H B. 2019. Non-blind image deblurring method by the total variation deep network. *IEEE Access*, 7: 37536-37544 [DOI: 10.1109/ACCESS.2019.2891626]
- Xu L and Jia J Y. 2010. Two-phase kernel estimation for robust motion deblurring//*Proceedings of the 11th European Conference on Computer Vision (ECCV)*. Heraklion, Greece: Springer: 157-170 [DOI: 10.1007/978-3-642-15549-9_12]
- Xu L, Zheng S C and Jia J Y. 2013. Unnatural L0 sparse representation for natural image deblurring//*Proceedings of 2013 IEEE Conference on Computer Vision and Pattern Recognition*. Portland, USA: IEEE: 1107-1114 [DOI: 10.1109/CVPR.2013.147]
- Xu X Y, Pan J S, Zhang Y J and Yang M H. 2018. Motion blur kernel estimation via deep learning. *IEEE Transactions on Image Processing*, 27(1): 194-205 [DOI: 10.1109/TIP.2017.2753658]
- Yan Q S, Gong D, Wang P, Zhang Z, Zhang Y N and Shi J Q. 2023. SharpFormer: learning local feature preserving global representations for image deblurring. *IEEE Transactions on Image Processing*, 32: 2857-2866 [DOI: 10.1109/TIP.2023.3251029]
- Yan Y Y, Ren W Q, Guo Y F, Wang R and Cao X C. 2017. Image deblurring via extreme channels prior//*Proceedings of 2017 IEEE Conference on Computer Vision and Pattern Recognition*. Honolulu, USA: IEEE: 6978-6986 [DOI: 10.1109/CVPR.2017.738]
- Yang H. 2022. Survey of non-blind image restoration. *Chinese Optics*, 15(5): 954-972 (杨航. 2022. 非盲图像复原综述. *中国光学(中英文)*, 15(5): 954-972) [DOI: 10.37188/CO.2022-0099]
- Yang L G and Ji H. 2019. A variational EM framework with adaptive edge selection for blind motion deblurring//*Proceedings of 2017 IEEE/CVF Conference on Computer Vision and Pattern Recognition*. Long Beach, USA: IEEE: 10159-10168 [DOI: 10.1109/CVPR.2019.01041]
- Yang T, Ren P R, Xie X S and Zhang L. 2021. GAN prior embedded network for blind face restoration in the wild//*Proceedings of 2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition*. Nashville, USA: IEEE: 672-681 [DOI: 10.1109/CVPR46437.2021.00073]
- Yuan L, Sun J, Quan L and Shum H Y. 2008. Progressive inter-scale and intra-scale non-blind image deconvolution. *ACM Transactions on Graphics*, 27(3): 1-10 [DOI: 10.1145/1360612.1360673]
- Zamir S W, Arora A, Khan S, Hayat M, Khan F S and Yang M H. 2022. Restormer: efficient Transformer for high-resolution image restoration//*Proceedings of 2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition*. New Orleans, USA: IEEE: 5718-5729 [DOI: 10.1109/CVPR52688.2022.00564]
- Zamir S W, Arora A, Khan S, Hayat M, Khan F S, Yang M H and Shao L. 2021. Multi-stage progressive image restoration//*Proceedings of 2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition*. Nashville, USA: IEEE: 14816-14826 [DOI: 10.1109/CVPR46437.2021.01458]
- Zhang H G, Dai Y C, Li H D and Koniusz P. 2019a. Deep stacked hierarchical multi-patch network for image deblurring//*Proceedings of 2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition*. Long Beach, USA: IEEE: 5971-5979 [DOI: 10.1109/CVPR.2019.00613]
- Zhang J W, Pan J S, Ren J, Song Y B, Bao L C, Lau R W H and Yang M H. 2018. Dynamic scene deblurring using spatially variant recurrent neural networks//*Proceedings of 2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition*. Salt Lake City, USA: IEEE: 2521-2529 [DOI: 10.1109/CVPR.2018.00267]
- Zhang K, Zuo W M, Gu S H and Zhang L. 2017. Learning deep CNN denoiser prior for image restoration//*Proceedings of 2017 IEEE Conference on Computer Vision and Pattern Recognition*. Honolulu, USA: IEEE: 2808-2817 [DOI: 10.1109/CVPR.2017.300]
- Zhang K, Zuo W M and Zhang L. 2019b. Deep plug-and-play super-resolution for arbitrary blur kernels//*Proceedings of 2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition*. Long Beach, USA: IEEE: 1671-1681 [DOI: 10.1109/CVPR.2019.00177]
- Zhang K H, Luo W H, Zhong Y R, Ma L, Stenger B, Liu W and Li H D. 2020a. Deblurring by realistic blurring//*Proceedings of 2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. Seattle, USA: IEEE: 2734-2743 [DOI: 10.1109/CVPR42600.2020.00281]
- Zhang K H, Ren W Q, Luo W H, Lai W S, Stenger B, Yang M H and Li H D. 2022. Deep image deblurring: a survey. *International Journal of Computer Vision*, 130(9): 2103-2130 [DOI: 10.1007/s11263-022-01633-5]
- Zhang L, Zhang L, Mou X Q and Zhang D. 2011. FSIM: a feature similarity index for image quality assessment. *IEEE Transactions on Image Processing*, 20(8): 2378-2386 [DOI: 10.1109/TIP.2011.2109730]
- Zhang L M, Zhang H G, Chen J H and Wang L. 2020b. Hybrid deblurring net: deep non-uniform deblurring with event camera. *IEEE Access*, 8: 148075-148083 [DOI: 10.1109/access.2020.3015759]
- Zhang X D, Feng X C, Wang W W and Xue W F. 2013. Edge strength similarity for image quality assessment. *IEEE Signal Processing Letters*, 20(4): 319-322 [DOI: 10.1109/LSP.2013.2244081]
- Zhao Q, Yang H, Zhou D M and Cao J D. 2023. Rethinking image deblurring via CNN-Transformer multiscale hybrid architecture. *IEEE Transactions on Instrumentation and Measurement*, 72: 1-15 [DOI: 10.1109/TIM.2022.3230482]
- Zhou Q, Ding M Y and Zhang X M. 2020. Image deblurring using multi-stream bottom-top-bottom attention network and global information-

based fusion and reconstruction network. *Sensors*, 20(13): #3724 [DOI: 10.3390/s20133724]

Zoran D and Weiss Y. 2011. From learning models of natural image patches to whole image restoration//*Proceedings of 2011 International Conference on Computer Vision*. Barcelona, Spain: IEEE: 479-486 [DOI: 10.1109/ICCV.2011.6126278]

作者简介

胡张颖,女,硕士研究生,主要研究方向为图像去模糊。
E-mail:1022010309@njupt.edu.cn

周全,通信作者,男,教授,博士生导师,主要研究方向为计算机视觉和模式识别。E-mail:quan.zhou@njupt.edu.cn

陈明举,男,副教授,硕士生导师,主要研究方向为图像处理和机器学习。E-mail:chenmingju@suse.edu.cn

崔景程,男,本科生,主要研究方向为计算机视觉。
E-mail:b22011826@njupt.edu.cn

吴晓富,男,研究员,博士生导师,主要研究方向为机器学习与计算机视觉。E-mail:xfuwu@njupt.edu.cn

郑宝玉,男,教授,博士生导师,主要研究方向为计算机视觉、信号与信息处理。E-mail:zby@njupt.edu.cn